

Karakterisasi Volatilitas dan Deteksi Anomali Harga Pangan Strategis: Studi Kasus Pasar Tradisional Kota Manado, 2025-2026

Shalom Putri Maharani Taringanen

September 2026 (v1.0)

Abstrak

Penelitian ini membangun alur pemrosesan data untuk harga pangan harian yang dipublikasikan Bank Indonesia melalui Pusat Informasi Harga Pangan Strategis (PIHPS). Data mentah berformat lebar dengan 442 kolom ditransformasikan ke format panjang melalui prosedur pembersihan yang menangani lima kelas masalah kualitas data. Karakterisasi statistik terhadap 20 varian komoditas selama 440 hari survei menemukan pemisahan yang tajam antara komoditas hortikultura dan komoditas dengan intervensi harga. Nilai coefficient of variation berkisar dari 0,438 pada Cabai Merah Keriting hingga mendekati nol pada Gula Pasir Kualitas Premium. Sistem deteksi anomali dikembangkan melalui tiga iterasi, dengan iterasi terakhir menggunakan rolling median absolute deviation yang diberi batas bawah skala dan kriteria materialitas. Pengujian model prediktif memperlihatkan bahwa gradient boosting tidak berhasil mengungguli baseline naive pada data ini. Kegagalan tersebut ditelusuri pada dua sebab: ketidakmampuan ekstrapolasi model berbasis pohon, dan tingginya autokorelasi lag-1 yang menyisakan sedikit variasi untuk dipelajari.

Kata kunci: alur pemrosesan data, deteksi anomali, statistik robust, deret waktu, harga pangan

1. Pendahuluan

Harga pangan strategis berpengaruh langsung terhadap daya beli rumah tangga, sehingga pergerakannya rutin dipantau oleh otoritas ekonomi. Bank Indonesia mempublikasikan data harga harian melalui PIHPS untuk seluruh provinsi. Data tersebut terbuka untuk umum, tetapi formatnya belum siap dipakai untuk analisis komputasional.

Studi ini dilakukan dengan empat tujuan. Tujuan pertama adalah menyusun alur pemrosesan yang dapat direproduksi untuk mengubah data mentah menjadi format analitis. Tujuan kedua adalah mengarakterisasi perilaku statistik harga antar komoditas. Tujuan ketiga adalah mengembangkan sistem deteksi lonjakan harga yang tidak wajar. Tujuan keempat adalah menilai apakah metode pembelajaran mesin memberi nilai tambah dibanding pendekatan baseline yang sederhana.

Cakupan dibatasi pada pasar tradisional di Kota Manado, Provinsi Sulawesi Utara, dengan periode observasi 1 Januari 2025 sampai 8 September 2026.

2. Data dan Prapemrosesan

2.1 Sumber data

Data diambil dari PIHPS Bank Indonesia melalui antarmuka Tabel Harga Berdasarkan Daerah. Parameter yang dipilih adalah pasar tradisional, seluruh komoditas yang tersedia, dan tipe laporan harian. Berkas keluaran berupa satu lembar Excel berukuran 55,8 KB dengan dimensi 31 baris dan 442 kolom.

2.2 Karakteristik data mentah

Pemeriksaan awal terhadap berkas mentah menemukan lima kelas masalah yang harus ditangani sebelum analisis dimulai.

Masalah pertama adalah representasi numerik sebagai string. Nilai harga ditulis dengan koma sebagai pemisah ribuan, sehingga terbaca sebagai tipe teks dan tidak dapat dioperasikan secara aritmetis.

Masalah kedua adalah penyandian nilai hilang yang tidak standar. Sel tanpa data diisi karakter tanda hubung, bukan dibiarkan kosong. Akibatnya pemeriksaan nilai hilang standar melaporkan kelengkapan data seratus persen, dan laporan itu keliru.

Masalah ketiga adalah ketidakteraturan format temporal. Header kolom tanggal mengandung spasi internal dengan pola *dd/mm/yyyy*, sehingga rutin konversi tanggal konvensional gagal memprosesnya.

Masalah keempat adalah hierarki dua tingkat yang tercampur dalam satu tabel. Baris berpenanda angka Romawi merupakan kategori agregat yang nilainya rerata dari varian di bawahnya, sedangkan baris berpenanda angka Arab merupakan varian individual. Agregasi yang mencampur kedua tingkat akan menghasilkan penghitungan ganda.

Masalah kelima adalah cakupan komoditas yang tidak seragam antar daerah. Komoditas Cabai Merah Besar terdaftar pada antarmuka filter, tetapi tidak tersedia di wilayah studi.

2.3 Transformasi ke format panjang

Data ditransformasikan dari format lebar ke format panjang mengikuti prinsip tidy data [6], sehingga setiap baris mewakili satu observasi tunggal berupa pasangan komoditas dan tanggal.

Penanda tingkat hierarki diekstraksi dari kolom penomoran. Nilai yang termasuk himpunan angka Romawi diklasifikasikan sebagai kategori, sisanya sebagai varian. Nama kategori kemudian dipropagasi ke bawah dengan forward fill agar setiap varian terhubung ke kategori induknya.

Keluaran akhir berjumlah 13.200 baris, mencakup 10 kategori dan 20 varian komoditas selama 440 hari survei. Seluruh analisis berikutnya dikerjakan pada subset varian saja, yaitu 8.800 observasi.

Survei tidak dilakukan pada akhir pekan, sehingga deret waktu yang dihasilkan tidak ekuidistan. Implikasinya dibahas pada Bagian 5.

3. Karakterisasi Statistik

3.1 Volatilitas antar komoditas

Perbandingan volatilitas antar komoditas dengan skala harga berbeda dilakukan menggunakan coefficient of variation:

$$CV_i = \frac{\sigma_i}{\mu_i}$$

dengan σ_i dan μ_i masing-masing simpangan baku dan rerata harga komoditas i sepanjang periode observasi. Normalisasi terhadap rerata diperlukan karena membandingkan simpangan baku mentah antara komoditas berharga Rp 130.000 dan Rp 40.000 tidak menghasilkan kesimpulan yang bermakna.

Hasilnya membentuk dua kelompok yang terpisah jelas. Kelompok bervolatilitas tinggi diisi komoditas hortikultura, yaitu Cabai Merah Keriting ($CV = 0,438$), Cabai Rawit Merah (0,385), Cabai Rawit Hijau (0,381), dan Bawang Merah Ukuran Sedang. Kelompok bervolatilitas rendah diisi seluruh varian beras dan gula pasir. Gula Pasir Kualitas Premium bahkan hampir tidak bergerak sepanjang 440 hari.

Pemisahan ini diduga berkaitan dengan dua faktor. Komoditas pada kelompok kedua umumnya memiliki mekanisme intervensi harga. Selain itu, komoditas hortikultura mudah rusak sehingga tidak dapat disimpan sebagai penyangga ketika pasokan terganggu.

3.2 Pengujian pola musiman

Hipotesis yang diuji menyatakan bahwa harga cabai mengikuti pola bulanan yang berulang antar tahun. Pengujian dilakukan dengan membandingkan rerata harga bulanan pada 2025 dan 2026.

Hasilnya tidak mendukung hipotesis tersebut. Puncak harga 2025 jatuh pada bulan ketiga, sedangkan puncak 2026 jatuh pada bulan kesembilan. Pada beberapa bulan, kedua tahun bahkan bergerak ke arah yang berlawanan.

Data hanya mencakup dua siklus tahunan, dan siklus kedua belum lengkap. Dua titik observasi tidak memadai untuk menyimpulkan ada atau tidaknya pola musiman. Kesimpulan yang tepat adalah bahwa pola musiman belum terbukti, bukan terbukti tidak ada.

3.3 Struktur autokorelasi

Kekuatan ketergantungan temporal diukur melalui korelasi Pearson antara harga pada waktu t dan harga pada waktu $t - k$:

$$\rho_k = \frac{Cov(P_t, P_{t-k})}{\sigma_{P_t} \sigma_{P_{t-k}}}$$

Pada Cabai Rawit Merah diperoleh $\rho_1 = 0,939$, $\rho_2 = 0,885$, $\rho_5 = 0,828$, $\rho_7 = 0,722$, $\rho_{14} = 0,343$, dan $\rho_{30} = -0,072$.

Pola peluruhan ini memperlihatkan memori sistem yang pendek, sekitar satu sampai dua minggu. Harga pada lag 30 hari tidak lagi memberi informasi prediktif. Temuan ini sejalan dengan hasil Bagian 3.2. Jika harga satu bulan sebelumnya saja tidak informatif, penanda kalender bulanan sewajarnya juga tidak informatif.

4. Deteksi Anomali

Sistem deteksi dibangun melalui tiga iterasi. Setiap iterasi gagal dengan mekanisme yang berbeda, dan analisis atas kegagalan tersebut mengarahkan perbaikan pada iterasi berikutnya.

4.1 Iterasi pertama: z-score global

Pendekatan awal menggunakan standardisasi terhadap keseluruhan periode. Untuk perubahan harian relatif $r_t = (P_t - P_{t-1}) / P_{t-1} \times 100$, skor dihitung sebagai:

$$z_t = \frac{r_t - \bar{r}}{s_r}$$

dengan ambang $|z_t| > 3$.

Hasilnya berkebalikan dengan ekspektasi. Frekuensi anomali tertinggi justru muncul pada beras (19 kejadian) dan gula pasir lokal (17 kejadian), sementara Cabai Rawit Merah hanya menghasilkan 10 kejadian meskipun rentang harganya mencapai tujuh kali lipat.

Mekanisme kegagalannya dapat diidentifikasi. Karena s_r dihitung per komoditas, komoditas dengan variabilitas rendah memiliki penyebut yang kecil, sehingga penyimpangan absolut yang kecil pun menghasilkan skor besar. Sebagai ilustrasi, kenaikan harga beras sebesar 10,71 persen dalam satu hari menghasilkan skor 9,49 sigma. Sementara itu, lonjakan cabai yang jauh lebih besar secara nominal tetap terhitung wajar menurut sebaran komoditas itu sendiri.

Metode ini sebenarnya menjawab pertanyaan tentang perubahan apa yang tidak lazim bagi suatu komoditas, bukan kapan terjadi guncangan harga yang berdampak.

4.2 Iterasi kedua: rolling median absolute deviation

Iterasi kedua memakai estimator robust berbasis median, mengikuti argumen Leys et al. [7] bahwa simpangan baku di sekitar rerata rentan terhadap pengaruh titik ekstrem itu sendiri. Median absolute deviation didefinisikan sebagai:

$$MAD_t = \text{median}(|r_i - \text{median}(r)|), \quad i \in [t - w, t]$$

dengan jendela $w = 30$ hari. Skor robust dihitung sebagai:

$$s_t = \frac{r_t - \text{median}(r)}{1,4826 \times MAD_t}$$

Konstanta 1,4826 adalah faktor konsistensi yang menyetarakan MAD dengan simpangan baku pada distribusi normal [8].

Iterasi ini menandai 771 dari 8.800 observasi, atau 8,76 persen, sebagai anomali. Proporsi sebesar itu terlalu besar untuk disebut kejadian tidak lazim.

Penyebabnya terletak pada perilaku data. Harga pangan kerap bertahan pada nilai yang sama persis selama beberapa hari berturut-turut. Pada periode seperti itu $r_t = 0$ secara terus-menerus, sehingga MAD_t mendekati nol dan penyebut pada persamaan skor menjadi sangat kecil. Perubahan yang secara praktis dapat diabaikan pun akhirnya menghasilkan skor besar.

Dampaknya paling terlihat pada Bawang Merah Ukuran Sedang yang menghasilkan 99 deteksi. Jumlah itu bukan cerminan gejolak pasar, melainkan akibat harganya sering datar lalu bergerak sedikit.

4.3 Iterasi ketiga: batas bawah skala dan kriteria materialitas

Iterasi terakhir memberi batas bawah pada skala:

$$\hat{s}_t = \frac{r_t - \text{median}(r)}{\max(1,4826 \times MAD_t, \delta)}$$

dengan $\delta = 0,5$. Selain itu ditambahkan kriteria materialitas, sehingga suatu observasi diklasifikasikan sebagai anomali hanya jika memenuhi kedua syarat berikut:

$$|\hat{s}_t| > \tau \quad \text{dan} \quad |r_t| \geq \eta$$

dengan $\tau = 4,0$ dan $\eta = 5\%$.

Konfigurasi ini menghasilkan 163 anomali dari 8.800 observasi, atau 1,85 persen. Distribusi anomali antar komoditas kini sejalan dengan peringkat volatilitas pada Bagian 3.1. Empat posisi teratas diisi Cabai Rawit Hijau (38), Bawang Merah (35), Cabai Merah Keriting (32), dan Cabai Rawit Merah (30), sedangkan Gula Pasir Kualitas Premium hanya menghasilkan satu kejadian.

Dari proses ini dapat ditarik satu prinsip yang berlaku lebih luas. Sistem deteksi anomali yang operasional membutuhkan signifikansi statistik dan signifikansi praktis sekaligus. Penyimpangan yang terdeteksi secara matematis tetapi berskala kecil tidak berguna bagi pengambilan keputusan.

Batasan metode ini dinyatakan secara terbuka. Formulasi di atas mendeteksi percepatan perubahan, bukan level harga. Harga tertinggi dalam suatu periode tidak akan ditandai apabila kenaikannya berlangsung bertahap.

5. Evaluasi Model Prediktif

5.1 Protokol pengujian

Data dipartisi secara kronologis dengan proporsi 80 persen untuk pelatihan dan 20 persen untuk pengujian. Partisi acak sengaja dihindari karena pada data deret waktu hal itu menyebabkan kebocoran informasi dari masa depan ke masa lalu, sebagaimana dibahas Bergmeir dan Benítez [9].

Metrik evaluasi yang dipakai adalah mean absolute error dan mean absolute percentage error:

$$MAE = \frac{1}{n} \sum |y_t - \hat{y}_t|$$

$$MAPE = \frac{100}{n} \sum \left(\left| \frac{y_t - \hat{y}_t}{y_t} \right| \right)$$

Keterbatasan MAPE sebagai metrik sudah terdokumentasi dengan baik [10]. Metrik ini tetap dipilih karena mudah ditafsirkan, dan dilaporkan berdampingan dengan MAE.

5.2 Baseline

Tiga baseline ditetapkan sebelum model diuji. Baseline naive memakai $\hat{y}_t = y_{t-1}$, yang merupakan prediktor standar untuk deret yang mendekati sifat random walk [11]. Baseline kedua adalah rerata bergerak tujuh hari. Baseline ketiga adalah rerata global.

Baseline	MAE (Rp)	MAPE (%)
Naive	6.537	8,09
Rerata bergerak 7 hari	11.809	16,03
Rerata global	26.063	36,68

Baseline rerata bergerak kalah telak dari baseline naive. Ini menjadi indikasi awal bahwa penghalusan justru membuang informasi yang paling prediktif pada data ini.

5.3 Konfigurasi model dan hasil

Model histogram-based gradient boosting [12, 13] diuji dalam tiga konfigurasi.

Konfigurasi	Target	Fitur	MAE (Rp)	MAPE (%)
A	Level harga	12	8.969	10,01
B	Perubahan relatif	12	6.979	8,91
C	Perubahan relatif	3	6.682	8,39

Tidak ada satu pun konfigurasi yang berhasil mengungguli baseline naive.

5.4 Diagnosis

Kegagalan Konfigurasi A bersifat struktural. Model berbasis ansambel pohon keputusan menghasilkan prediksi sebagai rerata terbobot dari nilai target pada daun, sehingga secara matematis tidak dapat menghasilkan prediksi di luar rentang nilai yang teramati saat pelatihan [14]. Pada data ini harga maksimum partisi pelatihan adalah Rp 125.000, sementara partisi pengujian mencapai Rp 165.000. Model tidak punya kapasitas untuk memprediksi angka itu, sebaik apa pun fiturnya.

Reformulasi target menjadi perubahan relatif pada Konfigurasi B menghilangkan batasan tersebut, sebab distribusi perubahan relatif bersifat relatif stasioner sepanjang periode.

Kegagalan Konfigurasi B teridentifikasi sebagai overfitting. Analisis permutation importance [15] memperlihatkan model bersandar pada fitur rerata bergerak tujuh hari sambil mengabaikan lag-1, padahal Bagian 3.3 menunjukkan lag-1 sebagai sinyal terkuat. Beberapa fitur bahkan bernilai kepentingan negatif, artinya perandoman fitur tersebut justru memperbaiki performa. Nilai negatif seperti itu adalah ciri khas fitur yang berperan sebagai derau. Dengan 349 observasi pelatihan, dimensi 12 fitur terlalu besar.

Reduksi menjadi tiga fitur disertai regularisasi yang lebih kuat pada Konfigurasi C memperbaiki MAPE sebesar 0,52 poin persentase. Perbaikan ini mengonfirmasi diagnosis tersebut.

Ketangguhan baseline naive dapat dijelaskan lewat struktur autokorelasi. Dengan $\rho_1 = 0,939$, sekitar 88 persen variasi harga pada $t + 1$ sudah dijelaskan oleh harga pada t . Sisa 12 persen sebagian besar berupa guncangan pasokan eksogen yang tidak meninggalkan jejak pada deret harga itu sendiri.

5.5 Implikasi

Evaluasi ini menyimpulkan bahwa penambahan kompleksitas model tidak memberi nilai tambah pada data dan periode yang diteliti. Keterbatasan yang dihadapi bersifat informasional, bukan algoritmik.

Arah pengembangan yang lebih menjanjikan adalah menambah variabel eksogen, misalnya data curah hujan, kalender hari besar keagamaan, indikator produksi pertanian, atau harga pada wilayah pemasok.

6 Implementasi Dashboard

Hasil analisis diimplementasikan sebagai aplikasi web interaktif dengan kerangka kerja Streamlit [16]. Aplikasi terdiri dari tiga modul: eksplorasi tren harga dengan penyaringan komoditas dan rentang waktu, peringkat volatilitas komparatif, serta visualisasi deteksi anomali beserta tabel rinciannya.

Hasil evaluasi model prediktif sengaja tidak diimplementasikan pada dashboard. Menyajikan prediksi yang berkinerja di bawah baseline sederhana kepada pengguna akhir berpotensi menyesatkan.

7 Kesimpulan

Studi ini memperlihatkan alur kerja pengolahan data publik secara utuh, dari berkas mentah dengan lima kelas masalah kualitas sampai produk akhir yang dapat diakses publik.

Tiga temuan utama diperoleh. Pertama, terdapat pemisahan struktural dalam volatilitas harga yang sejalan dengan perbedaan karakteristik komoditas. Kedua, sistem deteksi anomali yang operasional membutuhkan kriteria statistik dan kriteria materialitas sekaligus. Ketiga, pada horizon prediksi satu hari, baseline naive tidak berhasil diungguli oleh metode pembelajaran mesin.

Batasan. Cakupan terbatas pada satu kota dan satu jenis pasar. Periode observasi meliputi 20 bulan dengan tahun kedua belum lengkap. Evaluasi model hanya dilakukan pada satu komoditas. Periode pengujian mencakup lonjakan harga terbesar dalam keseluruhan data, dan lonjakan itu masih berlangsung ketika data diambil.

Pengembangan lanjutan. Perluasan cakupan ke beberapa kota untuk analisis komparatif spasial, otomatisasi pengambilan data harian, penambahan uji kualitas data otomatis pada alur pemrosesan, serta pengujian augmentasi dengan variabel eksogen.

Referensi

- [1] McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 56-61.
- [2] Harris, C. R., et al. (2020). Array programming with NumPy. *Nature*, 585, 357-362.
- [3] Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90-95.
- [4] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [5] Bank Indonesia. Pusat Informasi Harga Pangan Strategis (PIHPS Nasional). <https://www.bi.go.id/hargapangan>
- [6] Wickham, H. (2014). Tidy Data. *Journal of Statistical Software*, 59(10), 1-23.
- [7] Leys, C., Ley, C., Klein, O., Bernard, P., & Licata, L. (2013). Detecting outliers: Do not use standard deviation around the mean, use absolute deviation around the median. *Journal of Experimental Social Psychology*, 49(4), 764-766.
- [8] Rousseeuw, P. J., & Croux, C. (1993). Alternatives to the Median Absolute Deviation. *Journal of the American Statistical Association*, 88(424), 1273-1283.
- [9] Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences*, 191, 192-213.
- [10] Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679-688.
- [11] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- [12] Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, 29(5), 1189-1232.
- [13] Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 30.
- [14] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
- [15] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- [16] Streamlit Inc. Streamlit Documentation. <https://docs.streamlit.io>

Kode sumber: <https://github.com/ciputrii21/food-price-intelligence>

Dashboard: <https://food-price-intelligence.streamlit.app/>

Kontak: shalomputri21@gmail.com

Data: Bank Indonesia PIHPS Nasional, diakses September 2026